

Pseudo-Rotulagem Fraca para reconhecimento de entidades em relatos do Disque Denúncia

Tema 6 — Machine Learning

Junho de 2026

O Problema: Poucos Dados, Muitos Relatos

O Disque Denúncia recebe relatos diariamente:

 **DDlarge:** 184.493 relatos *sem anotação*

 **DDsmall:** 5.230 relatos *anotados manualmente*

Por que anotar manualmente é um problema?

- Especialista lê relato por relato
- Marca cada Pessoa, Local e Organização
- Processo **caro**, **lento** e **não escalável**
- 184 mil relatos não anotados ficam inutilizados

Exemplo de relato anotado

"... Ruan foi visto armado na Tijuca com integrantes da polícia. Segundo moradores de São Gonçalo..."

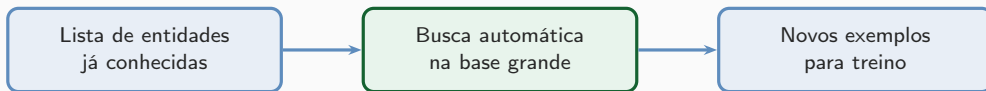
 Pessoa  Local  Organização

Dificuldades do domínio

- Linguagem informal e abreviações (*pm*, *cv*, *tcp*)
- Variações ortográficas (*polícia* / *policia*)
- Apelidos ("Ruan", "Mara")
- Entidades ambíguas ("Batalhão")

Hipótese do trabalho

Se uma entidade apareceu anotada no conjunto pequeno, ela pode reaparecer na base grande e gerar exemplos adicionais de treino. Isso pode expor o modelo a **mais contextos reais** e melhorar sua **generalização**.



Formulação da proposta

Em vez de marcar tudo do zero, o trabalho tenta **reaproveitar o que já foi aprendido no DDsmall** para gerar novas marcações no DDlarge.

De onde veio essa lista?

Apenas do **treino do DDsmall**, com **4.226** relatos.

- O texto já anotado foi percorrido relato por relato.
- Cada entidade marcada entrou em uma lista.
- Essa lista virou o ponto de partida do experimento.

Exemplo de lista

Ruan → Pessoa
Tijuca → Local
São Gonçalo → Local
polícia → Organização

A ideia aqui não era inventar entidades novas, e sim reunir as que já apareciam anotadas no conjunto de treino.

Etapa 2 – Filtragem do Léxico

Por que filtrar?


Grande parte das entidades aparecia muito poucas vezes no conjunto de treino, aumentando o risco de pseudo-anotações incorretas.

- Léxico inicial: **5.899 entidades**
- Removidas entidades com frequência ≤ 2
- Mantidas apenas entidades mais recorrentes

Resultado

5.899

Distribuição de frequência das entidades no léxico



A linha vermelha representa o corte adotado (frequência > 2). Observa-se que a maioria das entidades ocorria apenas uma ou duas vezes, sendo removida para reduzir o ruído do léxico.

O que é a projeção lexical?

É usar a lista de entidades conhecidas para procurar essas mesmas entidades nos relatos ainda não anotados.

Exemplo de lista

Ruan → Pessoa

Tijuca → Local

polícia → Organização

Relato do DDLarge

“Ruan foi visto na Tijuca com integrantes da polícia.”

Procedimento

Ele encontra automaticamente as ocorrências conhecidas e cria as marcações sem intervenção humana.

Depois da busca automática, alguns relatos do DDlarge passaram a ter marcações.

Esses relatos formaram um novo conjunto de treino auxiliar: o **corpus pseudo-anotado**.

Natureza dos pseudo-rótulos

As marcações não foram feitas por pessoas.

Elas foram geradas pelo algoritmo a partir da lista de entidades.

Resultado da projeção


133.841 relatos

com pelo menos uma marcação automática

450.833 entidades

no total

A projeção atingiu **72,5%** do DDlarge. O léxico ficou mais restrito depois da Etapa 2, então a cobertura caiu, mas a qualidade de cada marcação melhorou.



Configurações avaliadas: **Baseline 1** pré-treinado (pt_core_news_lg), **Baseline 2** treinado só no DDsmall, **Proposta 1** com EntityRuler e **Proposta 2** com DDsmall + pseudo-anotado.

Uma predição só é considerada correta quando o **span** e a **classe** coincidem exatamente com o gabarito.

Modelo	Pessoa			Localização			Organização			micro-F1
	P	R	F1	P	R	F1	P	R	F1	
Baseline 2 (DDsmall)	0,749	0,722	0,735	0,834	0,828	0,831	0,749	0,750	0,749	0,795
Proposta 2 (20k)	0,589	0,441	0,504	0,815	0,658	0,729	0,692	0,691	0,692	0,676
Proposta 1 (EntityRuler)	0,552	0,406	0,468	0,830	0,591	0,690	0,687	0,671	0,679	0,642
Proposta 2 (completo)	0,535	0,398	0,457	0,828	0,596	0,693	0,723	0,640	0,679	0,641
Baseline 1 (zero-shot)	0,408	0,495	0,447	0,409	0,347	0,375	0,254	0,149	0,187	0,362

O **Baseline 2** tem o melhor micro-F1. A **Proposta 1**, baseada só em regras, fica praticamente empatada com a **Proposta 2 completa**, 0,642 contra 0,641: usar mais dados pseudo-annotados não trouxe ganho adicional sobre o teto de um sistema de regras puro.

Como a avaliação foi feita

Todas as métricas abaixo foram medidas no **teste do DDsmall**, em **nível de entidade**: uma predição só conta como correta quando **span e classe** coincidem com o o rótulo verdadeiro.

Classe	Baseline 2			Proposta 2 (20k)		
	P	R	F1	P	R	F1
Pessoa	0,749	0,722	0,735	0,589	0,441	0,504
Local	0,834	0,828	0,831	0,815	0,658	0,729
Organização	0,749	0,750	0,749	0,692	0,691	0,692
Micro	0,800	0,791	0,795	0,745	0,620	0,676
Macro F1	—	—	0,772	—	—	0,641

Contagem de erros

Baseline 2: **605 FP, 639 FN, 119 erros de classe**.

Proposta 2 (20k): **650 FP, 1.163 FN, 83 erros de classe**.

Maior impacto por classe

Pessoa teve a maior queda de F1, de **0,735** para **0,504**. **Organização** foi a classe que caiu menos, de **0,749** para **0,692**.

Léxico extraído do treino

5.899 entidades brutas; **1.057** mantidas; **4.842** removidas.

Por classe: Local **662**, Pessoa **248**, Organização **147**.

Mantidos: *polícia, São Gonçalo, rj*, sigla de exceção.

Removidos: *sg, Fernando beira mar, Flamengo, Botafogo*.

Pseudo-anotação no DDlarge

133.841 relatos pseudo-annotados

450.833 pseudo-entidades


Por classe: Local **236.763**, Organização **142.636**, Pessoa **71.434**.

Inspeção manual da amostra

Houve casos plausíveis, como *São Gonçalo* e *Jardim Catarina* marcados como **Local**.

Mas também surgiram termos ambíguos, como *posse* e *PROVIDENCIA* marcados como Local fora de contexto.

A projeção lexical **não usa contexto**: o mesmo termo tende a receber o mesmo rótulo mesmo em usos ambíguos.



Síntese dos resultados

A hipótese **não** foi confirmada.

O modelo com pseudo-rótulos ficou abaixo do baseline supervisionado.

Entre as configurações, o melhor resultado ficou com o **Baseline 2**. A pseudo-anotação não melhorou a generalização no teste, e a queda foi especialmente forte em **Pessoa**, enquanto **Organização** caiu menos.

1. Entidades fora do léxico dispararam

Os **falsos negativos fora do léxico** passaram de **188** no Baseline 2 para **557** na Proposta 2 (20k).

O léxico ficou bem menor depois da Etapa 2, então muitas entidades legítimas nunca chegaram a ser pseudo-annotadas.

2. Variantes ortográficas continuaram difíceis

Os **falsos negativos por variação ortográfica** subiram de **68** para **219**.

O pseudo-corpus reforça as formas exatas do léxico, e o léxico agora cobre menos variantes de cada entidade.

3. Entidades compostas fragmentaram mais

O erro **composta _parcial** quase dobrou: de **110** para **217**.

Exemplo: *morro do canta galo* reconhecido só como *canta galo*.

Os **falsos positivos** quase não mudaram (**264** → **296**): o filtro de frequência mínima da Etapa 2 já limita a entrada de termos ambíguos no léxico. O **erro de classe** até melhorou (**119** → **83**). O problema da Proposta 2 não é ruído: é **perda de cobertura**.

Síntese do estudo

O trabalho investigou se a projeção lexical sobre o DDLarge poderia gerar exemplos adicionais de treino e melhorar a generalização do modelo.

Síntese dos achados

A resposta foi **negativa**: o filtro de frequência mínima do léxico reduziu bastante o ruído, mas isso custou **cobertura**, e essa perda de cobertura piorou o modelo em vez de melhorá-lo.

Conclusão geral

A hipótese não foi confirmada. O principal resultado não é apenas esse, mas entender **por que** ela falhou: a projeção lexical decide marcar uma entidade só por correspondência exata de texto, sem usar contexto. Um léxico mais restrito reduz o ruído, mas também reduz a cobertura, e foi essa perda de cobertura que impediu a Proposta 2 de superar o baseline supervisionado.

Obrigado!

Dúvidas?