
Trabalho 3 - Tema 6

CIC1205 - Machine Learning

Prof. Eduardo Bezerra

June 2, 2026

0 Contents

1 Contexto	1
2 Tema	2
3 Objetivo	2
4 Conjunto de dados	3
5 Entidades consideradas	3
6 Abordagem proposta	4
6.1 Etapa 1: extração do léxico de entidades	4
6.2 Etapa 2: normalização e filtragem do léxico	4
6.3 Etapa 3: projeção lexical sobre o DDlarge	5
6.4 Etapa 4: construção do corpus pseudo-anotado	5
6.5 Etapa 5: treinamento dos modelos	6
7 Modelos e configurações experimentais	6
8 Métricas de avaliação	7
9 Análises obrigatórias	7
9.1 Análise do léxico	7
9.2 Análise das pseudo-anotações	7
9.3 Análise qualitativa de erros	8
10 Cuidados metodológicos	8
11 Extensões opcionais	8
12 Resultados esperados	9
13 Entregáveis	9
14 Resumo do escopo mínimo	10

1 Contexto

Relatos criminais registrados no serviço Disque Denúncia constituem uma fonte rica de informação para apoio à segurança pública. Esses relatos são escritos em linguagem natural, frequentemente informal, com abreviações, erros ortográficos, variações de grafia, apelidos, referências locais e expressões características do domínio criminal. Por esse motivo, a extração automática de informações estruturadas a partir desses textos é uma tarefa desafiadora.

A dissertação de Gustavo Melo investigou o problema de Reconhecimento de Entidades Nomeadas (REN) em relatos criminais informais do Disque Denúncia. O objetivo central

foi identificar automaticamente entidades dos tipos **Pessoa**, **Localização** e **Organização**. O trabalho utilizou um corpus manualmente anotado, denominado **DDsmall**, e um corpus maior, não anotado manualmente, denominado **DDlarge**. O **DDsmall** contém 5.230 relatos e 20.101 entidades anotadas, enquanto o **DDlarge** contém 368.854 relatos, o que caracteriza um cenário típico de escassez de rótulos e grande volume de dados não rotulados.

Na dissertação, a estratégia principal para explorar o **DDlarge** foi baseada em pseudo-rotulagem com modelos de linguagem, especialmente o **GLiNER**. Essa abordagem é poderosa, mas pode ser computacionalmente custosa para um trabalho de curta duração. Este tema propõe investigar uma alternativa mais simples, interpretável e barata: utilizar as entidades reconhecidas no conjunto de treino como um léxico supervisionado e projetar essas entidades sobre o **DDlarge** para gerar pseudo-anotações fracas.

A hipótese a ser investigada é que entidades já conhecidas, quando reaparecem em novos relatos, podem ser usadas para produzir exemplos adicionais de treinamento. Esses exemplos não necessariamente introduzem novas entidades, mas expõem o modelo a uma maior diversidade de contextos reais em que as entidades aparecem. Isso pode ajudar o modelo a aprender padrões contextuais associados a pessoas, locais e organizações em relatos criminais.

2 Tema

O tema deste trabalho é:

Pseudo-rotulagem fraca para reconhecimento de entidades em relatos do Disque Denúncia

O grupo deverá investigar se a projeção lexical de entidades anotadas no corpus de treino sobre o corpus **DDlarge** pode melhorar o desempenho de modelos leves de REN. A ideia é construir um dicionário de entidades a partir do conjunto anotado, aplicar esse dicionário ao corpus não anotado para gerar pseudo-rótulos e treinar modelos comparando diferentes formas de utilização desses dados pseudo-anotados.

3 Objetivo

O objetivo principal é avaliar experimentalmente se uma estratégia simples de pseudo-rotulagem por projeção lexical pode contribuir para o reconhecimento de entidades nomeadas em relatos criminais informais.

Mais especificamente, o grupo deverá:

1. extrair, a partir do conjunto de treino do **DDsmall**, um léxico de entidades anotadas dos tipos **Pessoa**, **Localização** e **Organização**;
2. projetar esse léxico sobre o **DDlarge**, identificando ocorrências textuais das entidades conhecidas em relatos não anotados;
3. gerar um corpus pseudo-anotado a partir dessas ocorrências;
4. treinar modelos leves de REN usando o **DDsmall** e o **DDlarge** pseudo-anotado;

5. comparar o desempenho da abordagem proposta com baselines treinados apenas no DDsmall;
6. analisar quantitativa e qualitativamente os ganhos e os erros introduzidos pela pseudo-rotulagem fraca.

Pergunta principal

A projeção de entidades conhecidas do conjunto de treino sobre um corpus maior não anotado melhora o desempenho de modelos leves de reconhecimento de entidades nomeadas em relatos criminais informais?

4 Conjunto de dados

O trabalho deverá utilizar os mesmos corpora considerados na dissertação de Gustavo Melo:

- **DDsmall**: corpus manualmente anotado, contendo relatos criminais do Disque Denúncia e entidades dos tipos Pessoa, Localização e Organização;
- **DDlarge**: corpus maior, sem anotações manuais de REN, contendo relatos criminais e metadados estruturados associados.

O **DDsmall** deverá ser usado para treinamento, validação e teste dos modelos. O grupo deverá respeitar a separação entre treino e teste. Em particular, o léxico de entidades usado na projeção lexical deverá ser extraído **apenas do conjunto de treino**. Nenhuma entidade do conjunto de teste deve ser usada na construção do léxico, para evitar vazamento de dados.

O **DDlarge** deverá ser usado como corpus não anotado para pseudo-rotulagem fraca. O grupo deverá aplicar o léxico extraído do treino sobre o DDlarge e gerar um conjunto de relatos pseudo-anotados. Esse conjunto pseudo-anotado será posteriormente combinado ao DDsmall para treinar ou ajustar um modelo de REN.

Cuidado com vazamento de dados

O conjunto de teste deve permanecer completamente isolado. As entidades presentes no teste não podem ser usadas para construir o léxico, ajustar regras, escolher exemplos pseudo-rotulados ou calibrar limiares. O teste deve ser usado apenas ao final, para comparar os modelos.

5 Entidades consideradas

O trabalho deverá considerar as três categorias de entidades da dissertação:

- **Pessoa**: nomes próprios, apelidos, alcunhas ou referências a indivíduos mencionados nos relatos;
- **Localização**: bairros, ruas, comunidades, morros, logradouros, pontos de referência e demais expressões espaciais relevantes;

- **Organização:** instituições, órgãos públicos, unidades policiais, facções, empresas, plataformas ou grupos organizados mencionados nos relatos.

O grupo deverá avaliar o desempenho separadamente por classe, pois as classes podem ter comportamentos diferentes. Em particular, entidades de localização tendem a ser mais frequentes, enquanto pessoas e organizações podem apresentar maior ambiguidade ou variação lexical.

6 Abordagem proposta

A abordagem proposta consiste em usar as entidades anotadas no conjunto de treino como uma fonte de supervisão fraca para gerar pseudo-anotações no DDlarge. Essa estratégia pode ser entendida como uma forma de *distant supervision* ou *weak supervision* baseada em léxico.

6.1 Etapa 1: extração do léxico de entidades

A primeira etapa consiste em percorrer o conjunto de treino do DDsmall e extrair todas as entidades anotadas. Para cada entidade, o grupo deverá armazenar pelo menos:

- texto da entidade;
- classe da entidade;
- frequência de ocorrência no treino;
- número de relatos distintos em que a entidade aparece.

Por exemplo, se uma entidade aparece várias vezes como Localização, ela deverá ser registrada como uma candidata a termo do léxico de Localização.

Entidades muito raras, muito curtas ou muito ambíguas podem ser removidas do léxico. Essa filtragem é importante para reduzir a geração de pseudo-rótulos incorretos.

6.2 Etapa 2: normalização e filtragem do léxico

Antes de projetar o léxico sobre o DDlarge, o grupo deverá realizar uma etapa de normalização e filtragem. Recomenda-se considerar os seguintes critérios:

1. converter textos para uma forma normalizada para comparação, por exemplo caixa baixa e remoção de espaços duplicados;
2. manter uma correspondência entre a forma normalizada e o texto original, para recuperar corretamente os spans no relato;
3. remover entidades com tamanho muito pequeno, salvo siglas relevantes do domínio;
4. remover entidades compostas apenas por palavras muito genéricas, como “rua”, “morro”, “comunidade”, “elementos” ou “bandidos”, quando essas palavras aparecerem isoladamente;
5. resolver conflitos quando a mesma superfície textual aparecer associada a mais de uma classe.

Um conflito ocorre, por exemplo, quando a mesma string aparece anotada como Pessoa em alguns relatos e como Localização ou Organização em outros. Nesses casos, o grupo poderá adotar uma das seguintes estratégias:

- remover a entidade conflituosa do léxico;
- manter apenas a classe mais frequente;
- manter a entidade apenas se uma classe for claramente dominante, por exemplo acima de 80% das ocorrências.

Regra recomendada

Para o escopo mínimo, recomenda-se remover entidades conflituosas ou manter apenas entidades cuja classe majoritária represente pelo menos 80% das ocorrências no conjunto de treino. Essa regra reduz a chance de propagar erros para o DDlarge.

6.3 Etapa 3: projeção lexical sobre o DDlarge

A projeção lexical consiste em buscar, nos relatos do DDlarge, ocorrências das entidades presentes no léxico. Quando uma entidade do léxico é encontrada no texto de um relato, o span correspondente é pseudo-anotado com a classe da entidade.

Essa etapa deve ser feita com cuidado. O grupo não deve simplesmente procurar substrings de forma ingênua. Recomenda-se utilizar:

- casamento com fronteiras de palavra;
- preferência por entidades mais longas quando houver sobreposição entre spans;
- controle de conflitos entre entidades que se sobrepõem;
- preservação dos índices de início e fim no texto original;
- limitação do número de pseudo-entidades por relato, se necessário.

Por exemplo, se o léxico contém “Avenida Brasil” e “Brasil”, e o relato contém “Avenida Brasil”, deve-se preferir a entidade mais longa. Essa decisão evita que uma entidade composta seja fragmentada artificialmente.

6.4 Etapa 4: construção do corpus pseudo-anotado

Após a projeção lexical, o grupo deverá construir um conjunto pseudo-anotado derivado do DDlarge. Cada relato pseudo-anotado deverá conter:

- texto original do relato;
- lista de spans pseudo-anotados;
- classe de cada span;
- origem da anotação, indicando que se trata de pseudo-rótulo gerado por projeção lexical.

O grupo deverá documentar quantos relatos do DDlarge receberam pelo menos uma pseudo-anotação, quantas entidades foram geradas por classe e qual foi a distribuição dos pseudo-rótulos.

6.5 Etapa 5: treinamento dos modelos

O grupo deverá treinar modelos leves de REN comparando diferentes cenários. A recomendação principal é utilizar a biblioteca **spaCy**, por permitir combinar regras baseadas em léxico com um componente de NER treinável.

Uma configuração possível é usar:

- **EntityRuler** para representar o léxico de entidades;
- componente **ner** do **spaCy** para treinar um modelo supervisionado;
- formato **DocBin** para armazenar os exemplos anotados e pseudo-anotados.

O grupo poderá também testar outro modelo leve, desde que justifique a escolha e mantenha o foco na comparação entre treino apenas com DDsmall e treino com DDsmall acrescido do DDlarge pseudo-anotado.

7 Modelos e configurações experimentais

O grupo deverá comparar, no mínimo, as seguintes configurações:

Configuração	Descrição
Baseline 1	Modelo spaCy pré-treinado em português, aplicado diretamente ao conjunto de teste, sem adaptação ao domínio.
Baseline 2	Modelo NER treinado apenas com o conjunto de treino do DDsmall.
Proposta 1	EntityRuler construído com entidades extraídas do treino e aplicado diretamente ao teste como sistema baseado em regras.
Proposta 2	Modelo NER treinado com DDsmall combinado a uma amostra do DDlarge pseudo-anotado por projeção lexical.

Table 1: Configurações experimentais mínimas para comparação.

A comparação mais importante é entre o modelo treinado apenas com o DDsmall e o modelo treinado com **DDsmall + DDlarge pseudo-anotado**. Essa comparação permitirá avaliar se a pseudo-rotulagem fraca contribui para melhorar a capacidade de generalização do modelo.

Amostragem do DDlarge

Não é necessário usar todo o DDlarge. O grupo poderá trabalhar com uma amostra do corpus, desde que documente claramente o critério de seleção e o número de

relatos utilizados. Recomenda-se começar com uma amostra pequena e aumentar progressivamente, se houver tempo.

8 Métricas de avaliação

A avaliação deverá ser realizada sobre o conjunto de teste manual do DDsmall. O grupo deverá reportar as seguintes métricas:

- precisão por classe;
- revocação por classe;
- F1 por classe;
- F1 macro;
- F1 micro;
- número de falsos positivos, falsos negativos e erros de classe.

A avaliação principal deverá ser feita em nível de entidade, isto é, uma predição deve ser considerada correta apenas quando o span e a classe coincidirem com a anotação de referência.

Sempre que possível, o grupo deverá também apresentar resultados em nível de token como análise complementar, mas a métrica principal do trabalho será o F1 em nível de entidade.

9 Análises obrigatórias

Além das métricas quantitativas, o grupo deverá realizar análises para compreender o comportamento da estratégia proposta.

9.1 Análise do léxico

O grupo deverá apresentar:

- número de entidades distintas extraídas do treino;
- número de entidades por classe;
- entidades removidas por filtros de tamanho ou ambiguidade;
- exemplos de entidades mantidas e removidas;
- distribuição de frequência das entidades no treino.

9.2 Análise das pseudo-anotações

O grupo deverá apresentar:

- número de relatos pseudo-annotados no DDlarge;
- número total de pseudo-entidades geradas;

- distribuição de pseudo-entidades por classe;
- exemplos de relatos pseudo-annotados;
- amostra manual de pseudo-annotações corretas e incorretas.

9.3 Análise qualitativa de erros

O grupo deverá inspecionar manualmente uma amostra dos erros cometidos pelos modelos. Recomenda-se classificar os erros em categorias como:

- falso positivo causado por termo ambíguo;
- falso negativo por variação ortográfica;
- erro de classe entre Pessoa, Localização e Organização;
- erro de fronteira do span;
- entidade informal ou apelido não presente no léxico;
- entidade composta reconhecida apenas parcialmente.

Essa análise é importante porque a estratégia de projeção lexical pode melhorar a cobertura em alguns casos, mas também pode introduzir ruído em termos ambíguos.

10 Cuidados metodológicos

O grupo deverá observar os seguintes cuidados:

1. **Evitar vazamento de dados:** o léxico deve ser extraído apenas do conjunto de treino.
2. **Preservar o teste:** o conjunto de teste só deve ser usado na avaliação final.
3. **Controlar ambiguidade:** entidades que aparecem com classes diferentes devem ser removidas ou tratadas com regra explícita.
4. **Evitar casamento ingênuo:** a projeção lexical deve usar fronteiras de palavra e resolver sobreposições.
5. **Documentar filtros:** todas as regras de limpeza e filtragem do léxico devem ser descritas no relatório.
6. **Comparar de forma justa:** todos os modelos devem ser avaliados no mesmo conjunto de teste.

Armadilha comum

A projeção lexical não deve ser confundida com anotação manual nem com um modelo perfeito. Os rótulos produzidos no DDLarge são pseudo-rótulos fracos e podem conter erros. O objetivo do trabalho é justamente investigar se, apesar desse ruído, eles ajudam o modelo a aprender melhores padrões de REN.

11 Extensões opcionais

Caso o grupo avance além do escopo mínimo, poderá explorar uma ou mais das seguintes extensões:

- usar metadados do DDlarge, como bairro, logradouro, cidade e ponto de referência, para reforçar pseudo-rótulos de Localização;
- comparar diferentes tamanhos de amostra do DDlarge pseudo-annotado;
- testar diferentes limiares de frequência mínima para incluir entidades no léxico;
- comparar projeção lexical exata com casamento aproximado, por exemplo usando similaridade textual;
- treinar um modelo BERTimbau para classificação de tokens como comparação adicional;
- comparar o desempenho da projeção lexical com pseudo-rótulos produzidos por um modelo de REN pré-treinado.

12 Resultados esperados

Espera-se que o grupo produza uma avaliação experimental clara sobre a utilidade da pseudo-rotulagem fraca para REN em relatos criminais informais.

Um resultado positivo seria observar que o modelo treinado com DDsmall + DDlarge pseudo-annotado apresenta melhora em F1, especialmente em classes ou contextos com maior diversidade lexical. No entanto, mesmo que o desempenho global não melhore, o trabalho ainda poderá ser relevante se identificar os regimes em que a estratégia ajuda ou prejudica.

Em particular, o grupo deverá discutir:

- se o DDlarge pseudo-annotado aumenta a revocação;
- se a projeção lexical introduz muitos falsos positivos;
- quais classes se beneficiam mais da estratégia;
- quais tipos de entidade são mais problemáticos;
- se a estratégia é competitiva como alternativa leve a modelos mais pesados de pseudo-rotulagem.

13 Entregáveis

O grupo deverá entregar:

1. código-fonte organizado e reproduzível;
2. script ou notebook para extração do léxico a partir do treino;
3. script ou notebook para projeção lexical sobre o DDlarge;

4. corpus pseudo-annotado gerado, ou instruções para reconstruí-lo;
5. treinamento e avaliação dos modelos comparados;
6. relatório final com metodologia, resultados, análise de erros e discussão;
7. apresentação final resumindo a hipótese, a abordagem, os experimentos e as conclusões.

14 Resumo do escopo mínimo

O escopo mínimo do trabalho consiste em:

1. dividir corretamente o DDsmall em treino, validação e teste, ou utilizar a divisão já fornecida;
2. extrair um léxico de entidades apenas do treino;
3. projetar esse léxico sobre uma amostra do DDlarge;
4. gerar pseudo-annotações fracas;
5. treinar um modelo NER leve com DDsmall;
6. treinar outro modelo com DDsmall + DDlarge pseudo-annotado;
7. avaliar ambos no mesmo conjunto de teste manual;
8. analisar quantitativamente e qualitativamente os resultados.

Contribuição esperada

A contribuição do trabalho será avaliar se uma estratégia simples, barata e interpretável de pseudo-rotulagem por projeção lexical pode produzir ganhos em reconhecimento de entidades nomeadas em relatos criminais informais, servindo como alternativa ou complemento a abordagens mais pesadas baseadas em modelos de linguagem.