

Pseudo-rotulagem fraca para reconhecimento de entidades em relatos do Disque Denúncia

Trabalho 3 – Tema 6
CIC1205 – Machine Learning

Junho de 2026

Sumário

1	Contexto e motivação	3
2	Conjuntos de dados	3
3	Entidades consideradas	4
4	Metodologia	4
4.1	Etapa 1: extração do léxico de entidades	4
4.2	Etapa 2: normalização e filtragem do léxico	5
4.3	Etapa 3: projeção lexical sobre o DDlarge	6
4.4	Etapa 4: construção do corpus pseudo-anotado	7
4.5	Etapa 5: treinamento dos modelos	7
5	Modelos e configurações experimentais	8
6	Métricas de avaliação	8
7	Análises	10
7.1	Análise do léxico	10
7.2	Análise das pseudo-anotações	10
7.3	Análise qualitativa de erros	11
7.3.1	Falsos negativos fora do léxico	11
7.3.2	Falsos negativos por variação ortográfica	12

7.3.3	Entidades compostas reconhecidas parcialmente	12
7.3.4	Falsos positivos	12
7.3.5	Erros de classe e entidades no léxico não reconhecidas	12
8	Cuidados metodológicos	13
9	Conclusões	13

1 Contexto e motivação

O reconhecimento automático de entidades nomeadas (REN) em textos informais é uma das tarefas mais desafiadoras do processamento de linguagem natural. Quando esses textos vêm de um domínio especializado, como relatos criminais registrados em serviços de segurança pública, as dificuldades se multiplicam: a linguagem é repleta de abreviações, apelidos, variações ortográficas e referências locais que raramente aparecem em corpora genéricos usados para treinar modelos padrão.

O ponto de partida deste trabalho é a dissertação de mestrado de Gustavo Melo, que investigou o problema de REN em relatos informais do serviço Disque Denúncia do Rio de Janeiro. O objetivo central da dissertação foi identificar automaticamente entidades dos tipos Pessoa, Localização e Organização em textos brutos, sem estrutura predefinida. O corpus utilizado, chamado DDsmall, contém 5.230 relatos anotados manualmente. Além desse corpus anotado, existe um corpus muito maior e sem anotações manuais de REN, denominado DDlarge, com 184.493 relatos criminais. Na dissertação, a estratégia principal para aproveitar o DDlarge foi a pseudo-rotulagem com modelos de linguagem de grande porte, em particular o GLiNER, que avalia o contexto ao redor de cada candidato a entidade antes de atribuir um rótulo. Essa abordagem produz resultados expressivos, mas exige recursos computacionais consideráveis e tempo de treinamento elevado.

Este trabalho investiga uma alternativa mais simples e interpretável: usar as próprias entidades já anotadas no conjunto de treino como um dicionário de entidades conhecidas e, a partir desse dicionário, marcar automaticamente as ocorrências correspondentes nos relatos do DDlarge. Essa estratégia é conhecida na literatura como *projeção lexical* e a hipótese central é que os exemplos adicionais gerados dessa forma podem expor o modelo a uma maior diversidade de contextos reais, melhorando sua capacidade de generalização para entidades já conhecidas.

2 Conjuntos de dados

O trabalho utilizou os mesmos corpora considerados na dissertação de Gustavo Melo:

- **DDsmall:** corpus manualmente anotado, com 5.230 relatos distribuídos em três partições. O conjunto de treino contém 4.226 relatos, o conjunto de validação contém 212 relatos e o conjunto de teste contém 792 relatos. As anotações identificam entidades dos tipos Pessoa, Localização e Organização com seus respectivos spans de caracteres no texto original.
- **DDlarge:** corpus sem anotações manuais de REN, contendo 184.493 relatos criminais. Esse corpus foi usado exclusivamente como fonte de pseudo-anotação, nunca para avaliação.

O conjunto de teste do DDsmall foi mantido completamente isolado durante todo o desenvolvimento. Nenhuma entidade presente no teste foi usada para construir o léxico ou calibrar qualquer parâmetro. A avaliação final dos modelos foi realizada exclusivamente sobre esse conjunto.

Os relatos do DDsmall foram carregados a partir de arquivos JSON estruturados, onde cada registro contém um identificador único, o texto do relato e uma lista de spans anotados com início, fim e rótulo. O DDlarge foi processado em formato JSONL e percorrido de forma incremental para evitar consumo excessivo de memória, dado o volume de 184 mil registros.

3 Entidades consideradas

As três categorias de entidades seguem diretamente a definição adotada na dissertação de Gustavo Melo:

- **Pessoa:** nomes próprios, apelidos, alcunhas ou qualquer referência a indivíduos mencionados nos relatos, como “Ruan”, “Mara” ou “felipe branco”.
- **Localização:** bairros, ruas, comunidades, morros, logradouros, pontos de referência e demais expressões espaciais, como “São Gonçalo”, “favelinha” ou “estrada rio são Paulo”.
- **Organização:** instituições, órgãos públicos, unidades policiais, facções, empresas, plataformas ou grupos organizados, como “polícia”, “Facebook” ou “Batalhão”.

Essas três categorias apresentam comportamentos distintos. Localizações tendem a ser mais frequentes e mais estáveis em termos de grafia. Pessoas concentram alta variação lexical (apelidos informais, grafias inconsistentes) e são a categoria com maior queda de desempenho quando a pseudo-rotulagem é aplicada. Organizações ficam em posição intermediária, com algumas entidades muito frequentes e muitas outras raras ou ambíguas.

4 Metodologia

A abordagem proposta foi dividida em cinco etapas sequenciais: extração do léxico, filtragem, projeção lexical, construção do corpus pseudo-anotado e treinamento dos modelos.

4.1 Etapa 1: extração do léxico de entidades

A primeira etapa consistiu em percorrer os 4.226 relatos do conjunto de treino do DDsmall e registrar cada entidade anotada. Para cada ocorrência, foram armazenados: a forma de superfície original (texto exato extraído pelo span); o rótulo associado; a frequência total

de ocorrências no treino; o conjunto de documentos distintos em que a entidade aparece; e o conjunto de todas as formas ortográficas distintas observadas para a mesma entidade normalizada.

A chave do índice foi a forma normalizada de cada entidade: texto em minúsculas, sem acentos (usando decomposição Unicode NFKD com codificação ASCII) e com espaços duplicados colapsados. Essa normalização permitiu agrupar variantes como “polícia” e “policia” sob a mesma chave, preservando cada forma de superfície original para uso na projeção. O resultado foi um índice bruto com 5.899 entidades únicas (contadas por chave normalizada).

4.2 Etapa 2: normalização e filtragem do léxico

O índice bruto foi submetido a cinco filtros sequenciais para remover entradas com alto risco de gerar pseudo-anotações incorretas:

1. **Filtro de tamanho:** entidades com menos de 3 caracteres foram removidas, exceto aquelas presentes em uma lista de siglas do domínio (pm, cv, tcp, adf, bope, pmerj, upa, upp, rj, dp, br, pf). Esse filtro eliminou 51 entidades, como “sg”, com 15 ocorrências como Localização, “p2”, com 15 ocorrências majoritariamente como Organização, e “ph”, com 12 ocorrências como Pessoa. Siglas de alta frequência, como “rj”, com 217 ocorrências, e “dp”, permanecem no léxico por estarem na lista de exceções.
2. **Filtro de termos genéricos:** palavras isoladas consideradas excessivamente genéricas seriam removidas do léxico caso ocorressem como entidade completa (não apenas como parte de uma entidade composta), incluindo termos como “rua”, “morro”, “comunidade”, “elementos”, “bandidos”, “area”, “local”, “lugar”, “homem”, “mulher”, “beco” e “rodovia”. Na prática, nenhuma chave do índice bruto coincide exatamente com esses termos isolados. Eles aparecem nas anotações apenas como parte de spans maiores, como em “rua Augusto Rush”, de modo que esse filtro não eliminou nenhuma entrada nesta execução.
3. **Filtro de frequência mínima:** entidades observadas em duas ou menos ocorrências no treino foram descartadas. Esse filtro foi introduzido porque uma entidade com frequência 1 é 100% dominante em sua única classe observada, mesmo quando essa observação é um erro de anotação ou uma palavra comum usada fora de um contexto de entidade (ex.: “mão” anotada uma única vez como Pessoa). Esse foi o filtro mais impactante: eliminou 4.762 entidades, sendo 3.996 com frequência 1 e 766 com frequência 2.
4. **Filtro de dominância:** entidades associadas a mais de uma classe no treino foram mantidas apenas se uma classe representasse pelo menos 80% das ocorrências. Enti-

dades abaixo desse limiar foram descartadas por apresentar ambiguidade semântica. Esse filtro eliminou 29 entidades, como “flamengo”, com 6 ocorrências como Organização e 16 como Localização, uma dominância de apenas 72,7%, e “botafogo”, com 9 ocorrências como Localização, 7 como Organização e 2 como Pessoa, sem classe claramente dominante.

5. **Filtro de rótulo válido:** apenas entidades cuja classe dominante fosse uma das três válidas, Pessoa, Localização ou Organização, foram mantidas.

Ao final da filtragem, o léxico contou com 1.057 entidades válidas: 662 Localizações (62,6%), 248 Pessoas (23,5%) e 147 Organizações (13,9%). Essa filtragem representou uma redução de 82,1% em relação ao índice bruto, decorrente majoritariamente do filtro de frequência mínima.

A Figura 1 mostra a distribuição de frequência das entidades antes e depois da filtragem, em escala logarítmica. O índice bruto, com 5.899 entidades, tem mediana de frequência 1 e média 2,72. A maioria das entidades aparece em um único relato do treino. Após a filtragem, a mediana sobe para 5 e a média para 9,65, mantendo o máximo de 600 ocorrências para “polícia”, evidenciando que o léxico resultante é composto por entidades com evidência estatística bem mais robusta.

Distribuição de frequência das entidades no léxico




Figura 1: Distribuição de frequência das entidades no índice bruto (esquerda) e no léxico filtrado (direita), em escala logarítmica. A linha pontilhada marca o corte do filtro de frequência mínima.

4.3 Etapa 3: projeção lexical sobre o DDlarge

A projeção lexical buscou, nos relatos do DDlarge, ocorrências das entidades do léxico filtrado. Para isso, foi utilizado o `PhraseMatcher` da biblioteca `spaCy` com o atributo `LOWER`, que realiza casamento insensível a maiúsculas e minúsculas com base em tokens. O uso de tokens, em vez de busca por substring bruta, garante o respeito a fronteiras de palavra.

Internamente, o PhraseMatcher utiliza uma estrutura de busca baseada em trie, adaptada do algoritmo FlashText (Singh, 2017), para realizar a correspondência simultânea de grandes conjuntos de expressões. Essa abordagem permite localizar múltiplos padrões em uma única passagem pelo texto, mantendo bom desempenho mesmo quando milhares de termos são registrados. Essa característica viabilizou, com custo computacional reduzido, a projeção sobre os 184 mil relatos do DDlarge: o PhraseMatcher foi construído uma única vez com as 1.057 entidades do léxico filtrado antes do processamento dos registros. Para cada entidade, todas as formas observadas no conjunto de treino foram registradas como padrões distintos sob o mesmo rótulo.

A resolução de sobreposições seguiu a regra de preferir o span mais longo: quando dois spans se sobrepõem, o de maior comprimento é mantido e o mais curto é descartado. Isso evita que entidades compostas sejam fragmentadas em componentes menores. Empates de comprimento foram resolvidos pela posição mais à esquerda no texto.

4.4 Etapa 4: construção do corpus pseudo-anotado

Dos 184.493 relatos do DDlarge, 133.841 receberam pelo menos uma pseudo-anotação (72,5% do corpus). O total de pseudo-entidades geradas foi 450.833: 236.763 Localizações (52,5%), 142.636 Organizações (31,6%) e 71.434 Pessoas (15,8%).

Uma inspeção manual de amostras revelou tanto casos plausíveis quanto casos suspeitos. Entre os plausíveis: “São Gonçalo”, “Guaxindiba” e “Jardim Catarina” marcadas como Localização em relatos com contexto espacial coerente, e “upp” como Organização ao se referir a uma unidade policial. Entre os suspeitos estão “posse” marcada como Localização no trecho “mesmo com upp na região os meliantes praticam assaltos [...] em posse de”, um substantivo comum confundido com o topônimo homônimo do léxico, e “PROVIDENCIA” como Localização em contextos que não se referem ao Morro da Providência. A projeção também fragmenta entidades compostas que não estão registradas como tal no léxico: no relato “Dodô, felipe branco, e Sandro são alguns que comandam [...]”, o apelido “felipe branco” foi anotado como dois spans de Pessoa separados, “felipe” e “branco”, porque o léxico contém as duas palavras isoladamente, mas não a forma composta. O filtro de frequência mínima da Etapa 2 não é suficiente para eliminar casos como “posse” e “PROVIDENCIA”, cuja frequência no treino, 4 e 5 respectivamente, é alta o bastante para superar o filtro mesmo sendo ambíguos. Esses casos ilustram a limitação estrutural da projeção lexical: ela não avalia o contexto ao redor da ocorrência.

4.5 Etapa 5: treinamento dos modelos

Todos os modelos treinados do zero utilizaram a biblioteca spaCy com um pipeline em branco para o português (`spacy.blank('pt')`), ao qual foi adicionado o componente de

NER treinável. Os exemplos de treinamento foram construídos convertendo cada registro anotado em um objeto `Example` do spaCy, associando o texto original aos spans anotados. O treinamento foi executado com semente aleatória fixada em 42. Para a Proposta 2, os exemplos do DDsmall e os pseudo-exemplos do DDlarge foram combinados e embaralhados antes do treinamento.

5 Modelos e configurações experimentais

Foram comparadas cinco configurações:

Baseline 1 (zero-shot) O modelo pré-treinado `pt_core_news_lg` do spaCy, aplicado diretamente ao conjunto de teste sem adaptação ao domínio. Os rótulos originais (PER, LOC, ORG) foram mapeados para os rótulos do DDsmall (Pessoa, Localização, Organização).

Proposta 1 (EntityRuler) Sistema baseado puramente em regras, construído com o componente `EntityRuler` do spaCy. Para cada entidade do léxico, cada forma de superfície foi registrada como um padrão, com casamento insensível a maiúsculas. Os padrões foram ordenados do mais longo para o mais curto.

Baseline 2 (DDsmall) Modelo NER treinado exclusivamente com os 4.226 relatos do conjunto de treino do DDsmall. Representa o desempenho alcançável com a anotação manual disponível, sem dados adicionais.

Proposta 2 (20k pseudo) Modelo NER treinado com os 4.226 relatos do DDsmall combinados com os primeiros 20.000 relatos pseudo-anotados do DDlarge.

Proposta 2 (completo) Variante que utilizou todos os 133.841 relatos pseudo-anotados do DDlarge combinados com os 4.226 relatos do DDsmall.

6 Métricas de avaliação

A avaliação foi realizada no nível de entidade: uma predição é correta somente quando o span de início e fim coincide exatamente com a anotação de referência e o rótulo de classe também é correto. Foram reportadas precisão, revocação e F1 por classe, F1 micro, que soma os totais globais de TP, FP e FN, e F1 macro, a média simples entre as três classes.

Tabela 1: Avaliação em nível de entidade no conjunto de teste do DDsmall. Uma predição é correta somente quando span e classe coincidem exatamente.

Modelo	Pessoa			Localização			Organização			micro-F1
	P	R	F1	P	R	F1	P	R	F1	
Baseline 2 (DDsmall)	0,749	0,722	0,735	0,834	0,828	0,831	0,749	0,750	0,749	0,795
Proposta 2 (20k)	0,589	0,441	0,504	0,815	0,658	0,729	0,692	0,691	0,692	0,676
Proposta 1 (EntityRuler)	0,552	0,406	0,468	0,830	0,591	0,690	0,687	0,671	0,679	0,642
Proposta 2 (completo)	0,535	0,398	0,457	0,828	0,596	0,693	0,723	0,640	0,679	0,641
Baseline 1 (zero-shot)	0,408	0,495	0,447	0,409	0,347	0,375	0,254	0,149	0,187	0,362

O Baseline 2 obteve o melhor desempenho, com micro-F1 de 0,795. A melhor variante da Proposta 2, a de 20k, ficou em segundo lugar, com queda de 11,9 pontos percentuais. A Proposta 1, baseada puramente em regras, alcançou 0,642, ficando praticamente empatada com a Proposta 2 completa, que obteve 0,641 ao usar todos os 133.841 relatos pseudo-annotados em vez de apenas 20 mil. Isso sugere que ampliar a quantidade de pseudo-exemplos não trouxe ganho adicional depois que a Proposta 2 já supera o teto de um sistema de regras puro. O Baseline 1, zero-shot, ficou bem atrás de todas as demais configurações, com micro-F1 de 0,362.

7 Análises

7.1 Análise do léxico

Tabela 2: Visão geral do léxico extraído do conjunto de treino.

Medida	Valor
Entidades brutas (formas normalizadas únicas)	5.899
Entidades após filtragem	1.057
Entidades removidas	4.842
Por tamanho muito pequeno (<3 caracteres)	51
Por frequência mínima ($\text{freq} \leq 2$)	4.762
Por ambiguidade de classe (dominância $< 80\%$)	29
Localizações no léxico filtrado	662
Pessoas no léxico filtrado	248
Organizações no léxico filtrado	147
Frequência mediana (léxico filtrado)	5
Frequência média (léxico filtrado)	9,65
Frequência máxima (“polícia”)	600

No índice bruto, a distribuição de frequência é fortemente concentrada em valores baixos, com mediana 1, conforme mostra a Figura 1 apresentada na Etapa 2: a maioria das entidades aparece em apenas um relato do treino. O filtro de frequência mínima desloca essa distribuição no léxico final, cuja mediana sobe para 5. A entidade mais frequente, “polícia”, aparece 600 vezes como Organização. Entre as demais entidades frequentes estão “São Gonçalo”, com 192 ocorrências como Localização, “favelinha”, com 155, “Tijuca”, com 137, “Rio de Janeiro”, com 101, “Facebook”, com 100 ocorrências como Organização, e “pm”, com 86.

Entre as entidades removidas, os casos mais representativos são “sg”, removida pelo filtro de tamanho, “Fernando beira mar”, removida pelo filtro de frequência mínima com apenas 2 ocorrências como Pessoa, e “Ipase”, removida por ambiguidade: 4 ocorrências como Localização e 2 como Organização, dominância de apenas 67%.

7.2 Análise das pseudo-anotações

Dos 184.493 relatos do DDlarge, 133.841 receberam pelo menos uma pseudo-anotação, correspondendo a 72,5% do corpus. O total de 450.833 pseudo-entidades se distribui em 236.763 Localizações (52,5%), 142.636 Organizações (31,6%) e 71.434 Pessoas (15,8%), proporção próxima à observada no léxico filtrado.

A inspeção manual confirmou tanto casos plausíveis quanto suspeitos. Casos plausíveis incluem menções geográficas bem definidas como “São Gonçalo”, “Guaxindiba” e “Jardim Catarina” marcadas como Localização em contextos espaciais coerentes. Casos suspeitos incluem “posse” marcado como Localização em “[...] os meliantes praticam assaltos [...] em posse de” e “PROVIDENCIA” como Localização em contextos que não se referem ao Morro da Providência. Há também fragmentação de entidades compostas que não estão registradas como tal no léxico: “felipe branco” aparece anotado como dois spans de Pessoa separados (“felipe” e “branco”).

Esses erros não podem ser detectados pela projeção lexical sem uso de contexto, e representam ruído sistemático no corpus pseudo-anotado.

7.3 Análise qualitativa de erros

A comparação central é entre o Baseline 2 e a Proposta 2 (20k). A Tabela 3 apresenta os contadores de cada categoria de erro.

Tabela 3: Contagem de erros por categoria para o Baseline 2 e a Proposta 2 (20k). Acertos exatos não entram na contagem.

Categoria de erro	Baseline 2	Proposta 2 (20k)
Falso negativo / fora do léxico	188	557
Falso negativo / variação ortográfica	68	219
Erro de fronteira / composta parcial	110	217
Falso positivo (puro)	264	296
Erro de fronteira / span maior	109	52
Erro de classe	119	83
Falso negativo / no léxico, não reconhecida	42	33
Erro de fronteira / deslocado	3	2

7.3.1 Falsos negativos fora do léxico

Essa é a categoria que mais cresceu em termos absolutos, saltando de 188 para 557, um aumento de 196%. Como o léxico filtrado ficou bem menor depois do filtro de frequência mínima da Etapa 2, muitas entidades legítimas do DDlarge simplesmente nunca chegaram a ser pseudo-anotadas, e o modelo nunca viu exemplos delas durante o treinamento. Casos típicos incluem “supermercado vianense”, “IMPRENSA” e “Colubandê” classificadas como Organização ou Localização no conjunto de teste, mas ausentes do léxico usado para gerar o pseudo-corpus. Esse padrão aponta para uma queda de cobertura, não para ruído: o modelo da Proposta 2 ficou mais conservador, deixando de reconhecer entidades que o Baseline 2 já identificava corretamente.

7.3.2 Falsos negativos por variação ortográfica

Essa categoria mais que triplicou, de 68 para 219. Casos típicos incluem “Adriano” não reconhecido porque o léxico contém “adriana”, “Alexander” não reconhecida porque o léxico contém “alexandre”. O pseudo-corpus reforça as formas exatas do léxico, e como o léxico agora cobre menos variantes ortográficas de cada entidade, o modelo ficou mais rígido diante de grafias que não apareceram no treino.

7.3.3 Entidades compostas reconhecidas parcialmente

O erro de fronteira do tipo “composta parcial” quase dobrou, de 110 para 217. Exemplos incluem “morro do canta galo” reduzido a “canta galo”, “estrada rio são Paulo” reduzido a “rio” e “ponta da ilha” reduzido a “ilha”. A projeção tende a casar sub-strings frequentes do léxico, fragmentando entidades compostas cuja forma completa tem menor frequência do que seus componentes isolados.

7.3.4 Falsos positivos

Os falsos positivos cresceram pouco, de 264 para 296, um aumento de 12%. O filtro de frequência mínima do léxico, descrito na Etapa 2, descarta entidades raras antes que elas cheguem ao pseudo-corpus, o que limita a quantidade de termos ambíguos disponíveis para gerar ruído. Os casos que restam incluem “providência” marcado como Localização e “polimix” marcado como Organização, ambos termos que permanecem no léxico com frequência alta o suficiente para escapar do filtro. Essa categoria não é o principal fator de degradação da Proposta 2: as duas categorias de falso negativo discutidas acima, fora do léxico e variação ortográfica, têm impacto muito maior no total de erros.

7.3.5 Erros de classe e entidades no léxico não reconhecidas

Essas duas categorias, junto com o erro de fronteira do tipo “span maior”, foram as únicas em que a Proposta 2 melhorou. Os erros de classe caíram de 119 para 83, e as entidades do léxico não reconhecidas pelo modelo caíram de 42 para 33. Exemplos de erro de classe incluem “TOP SHOPPING” classificado como Organização quando o gabarito é Localização, e “marinha” classificado como Localização quando o gabarito é Organização. Essas melhorias sugerem que, para as entidades que de fato chegam a ser pseudo-anotadas, ver mais contextos ajuda o modelo a desambiguar a classe correta. O problema é que esse ganho é pequeno demais para compensar o aumento muito maior nas duas categorias de falso negativo.

8 Cuidados metodológicos

Os principais cuidados metodológicos adotados foram os seguintes. O léxico foi extraído exclusivamente dos 4.226 relatos do treino, sem acesso ao conjunto de teste. O conjunto de validação foi usado apenas para monitorar o treinamento e não influenciou a construção do léxico nem os limiares de filtragem. Todos os cinco modelos foram avaliados no mesmo conjunto de teste. A resolução de sobreposições na projeção foi determinística (span mais longo), evitando não-determinismo na geração do pseudo-corpus. Todas as sementes aleatórias foram fixadas em 42, tornando os resultados reprodutíveis. Os offsets de início e fim dos spans foram preservados em relação ao texto original, sem remapeamento.

9 Conclusões

Este trabalho investigou se a projeção lexical de entidades anotadas no conjunto de treino sobre um corpus maior e não anotado pode melhorar o desempenho de modelos leves de REN em relatos criminais informais. A hipótese não foi confirmada: em todas as configurações testadas, os modelos treinados com pseudo-rótulos ficaram abaixo do baseline treinado apenas com o corpus anotado manualmente.

A análise de erros aponta para uma tensão entre precisão e cobertura no léxico usado na projeção. O filtro de frequência mínima da Etapa 2 descarta qualquer entidade observada em até duas ocorrências no treino, reduzindo o índice bruto de 5.899 para as 1.057 entidades do léxico final. Essa exigência de evidência estatística limita a quantidade de termos ambíguos disponíveis para gerar ruído no pseudo-corpus: os falsos positivos da Proposta 2 cresceram apenas 12% sobre o Baseline 2, de 264 para 296. Em compensação, o léxico final cobre uma fração pequena das formas de entidade que aparecem no DDlarge, e isso aparece nos dois tipos de falso negativo que dominam o aumento total de erros: entidades fora do léxico, que quase triplicaram, de 188 para 557, e variantes ortográficas não cobertas pelas formas de superfície registradas, que também mais que triplicaram, de 68 para 219.

Essa tensão é consequência direta da limitação estrutural da projeção lexical: ela decide marcar ou não uma ocorrência apenas com base na correspondência de string, sem avaliar o contexto ao redor. Um léxico mais permissivo aumentaria a cobertura, mas também aumentaria o risco de marcar termos ambíguos fora de contexto, como “mão” ou “preto” usados como substantivo comum em vez de apelido, conforme discutido na Etapa 2. Um léxico mais restrito, como o usado neste trabalho, reduz esse risco, mas deixa de cobrir entidades raras e variantes ortográficas legítimas. As poucas categorias em que a Proposta 2 melhorou sobre o Baseline 2, erro de classe e entidades do léxico não reconhecidas, mostram que ver mais contextos ajuda o modelo a desambiguar quando a entidade chega a ser pseudo-anotada, mas esse ganho é pequeno demais para compensar o aumento nas

duas categorias de falso negativo.

Os resultados também mostram que ampliar o volume de pseudo-exemplos não traz ganho adicional: a variante com o corpus completo, usando 133.841 relatos, obteve micro-F1 de 0,641, abaixo da variante com apenas 20 mil relatos (0,676) e praticamente empatada com a Proposta 1, o sistema de regras puro (0,642). Isso sugere que o teto de desempenho da projeção lexical está mais ligado à qualidade e à cobertura do léxico do que à quantidade de relatos pseudo-annotados usados no treinamento.

Referências

Singh, V. (2017). Flashtext: A fast and memory-efficient method for searching multiple string keywords. *arXiv preprint arXiv:1711.00046*.